

UNIVERSIDADE NOVE DE JULHO — UNINOVE

Curso de Ciência da Computação / Sistemas de Informação

Turmas 43 + 44 + 185 · Campus Santo Amaro

Robert França de Queiroz Sampaio

RA: 2222201445

SISTEMA INTELIGENTE DE TRIAGEM E ALOCAÇÃO DE MÉDICOS

MedFácil Clínicas — Projeto de Extensão de Sistemas Inteligentes

Disciplina: Projeto de Extensão de Sistemas Inteligentes

Professor: Felipe Santos

São Paulo — 2026

RESUMO

O presente trabalho descreve o desenvolvimento de um Sistema Inteligente de Triagem e Alocação de Médicos para a MedFácil Clínicas, empresa fictícia do setor de saúde, no âmbito da disciplina de Projeto de Extensão de Sistemas Inteligentes. O projeto integra quatro disciplinas do semestre — Inteligência Artificial, Métodos Numéricos Computacionais, Modelagem e Simulação, e Automação de Processos — em uma solução computacional aplicada a um problema real de gestão operacional em unidades de pronto atendimento.

O problema central identificado consiste na alocação ineficiente de médicos por turno (Manhã, Tarde e Noite), que resulta em elevado custo operacional e capacidade ociosa significativa. A metodologia adotada compreende: (i) um pipeline ETL desenvolvido em Python para extração, limpeza e transformação de dataset público de saúde com 55.500 registros; (ii) Análise Exploratória de Dados (EDA) com geração de KPIs e dashboard visual; (iii) modelo de Programação Linear Inteira (PLI) implementado com a biblioteca PuLP para otimização da alocação de médicos por turno; e (iv) documentação de Segurança da Informação com mapeamento LGPD, Matriz GUT de riscos e Política de Autenticação.

Os resultados demonstram que a aplicação do modelo PLI permite reduzir o custo diário de pessoal de R\$ 10.080,00 para R\$ 6.240,00, representando uma economia de 38,1% e uma projeção de economia anual de R\$ 1.401.600,00. O modelo se mostrou robusto tanto para a demanda média quanto para o cenário de pico, validando a efetividade da abordagem. Todas as etapas foram desenvolvidas em conformidade com a LGPD, com anonimização de dados sensíveis de saúde implementada diretamente no pipeline ETL.

Palavras-chave: Inteligência Artificial. Programação Linear Inteira. Otimização de Turnos. Análise de Dados em Saúde. LGPD. Python.

Estrutura do Repositório

Todo o material do projeto está centralizado em pasta compartilhada no GitHub, compartilhada com o professor com permissão de leitura. Link do repositório: <https://github.com/robert-sampaio/medfacil>.

Assim como o link do vídeo da apresentação está aqui: <https://youtu.be/3S6xaa3CFJk>

1 INTRODUÇÃO

A gestão eficiente de recursos humanos em unidades de saúde representa um dos maiores desafios operacionais do setor. A alocação manual e intuitiva de médicos por turno, sem suporte de dados ou modelos analíticos, gera dois problemas recorrentes: a sobrecarga de profissionais em horários de pico e a ociosidade em períodos de baixa demanda — ambos com impacto direto no custo operacional e na qualidade do atendimento ao paciente.

A MedFácil Clínicas, empresa fictícia criada para este projeto, opera unidades de pronto atendimento em São Paulo e enfrenta exatamente esses problemas. Com um tempo médio de espera superior a 90 minutos em horários de pico e ausência total de dashboards gerenciais, a diretoria não dispõe de informações para tomar decisões baseadas em dados.

Este trabalho propõe a construção de um sistema de análise de dados e otimização capaz de: (a) processar e analisar dados históricos de atendimentos; (b) calcular indicadores-chave de desempenho (KPIs); (c) determinar a alocação ótima de médicos por turno através de um modelo de Programação Linear Inteira; e (d) garantir a conformidade com a Lei Geral de Proteção de Dados Pessoais (LGPD — Lei nº 13.709/2018) em todo o pipeline de dados.

1.1 Objetivos

1.1.1 Objetivo Geral

Desenvolver um sistema computacional integrado, utilizando Python e técnicas de Inteligência Artificial, para otimizar a alocação de médicos por turno na MedFácil Clínicas, reduzindo custos operacionais e melhorando a qualidade do atendimento. O sistema utiliza Inteligência Artificial baseada em otimização matemática — especificamente Programação Linear Inteira — para tomar decisões de alocação de recursos de forma autônoma e eficiente, minimizando custo sem intervenção humana.

1.1.2 Objetivos Específicos

- Construir um pipeline ETL em Python para extração, limpeza, transformação e anonimização de dataset público de saúde com 55.500 registros.
- Realizar Análise Exploratória de Dados (EDA) com identificação de padrões de demanda por turno, especialidade e período temporal.
- Calcular três KPIs principais: Tempo Médio de Espera (TME), Taxa de Ocupação por Turno e Volume de Atendimentos por Condição Médica.
- Desenvolver e resolver um modelo de Programação Linear Inteira (PLI) com três cenários de análise (Baseline, Otimizado e Pico).
- Documentar a conformidade com a LGPD através de mapeamento de dados pessoais, Matriz GUT de riscos e Política de Autenticação.

1.2 Justificativa

A aplicação de técnicas de Inteligência Artificial — especificamente otimização matemática via Programação Linear Inteira — na gestão de saúde é uma tendência consolidada globalmente. No Brasil, a escassez de médicos em determinadas especialidades e regiões torna a otimização da alocação de profissionais ainda mais crítica. Este projeto demonstra, em escala acadêmica, como ferramentas computacionais acessíveis — Python, PuLP, Pandas, Matplotlib — podem gerar economia significativa e embasar decisões gerenciais com dados concretos.

1.3 Organização do Documento

O presente documento está organizado em sete seções: a Seção 2 apresenta a revisão bibliográfica; a Seção 3 descreve a metodologia e as ferramentas utilizadas; a Seção 4 detalha o pipeline de dados e os métodos numéricos aplicados; a Seção 5 apresenta o modelo de IA e simulação; a Seção 6 trata da segurança e LGPD; a Seção 7 descreve a automação e gestão do projeto; e a Seção 8 consolida os resultados e conclusões.

2 REVISÃO BIBLIOGRÁFICA

2.1 Inteligência Artificial aplicada à Saúde

A aplicação de Inteligência Artificial (IA) no setor de saúde tem se expandido rapidamente nas últimas décadas. Segundo Topol (2019), sistemas de IA são capazes de superar especialistas humanos em tarefas diagnósticas específicas, como a identificação de melanomas e pneumonias em imagens médicas. No contexto de gestão hospitalar, a IA tem sido aplicada para previsão de demanda, alocação de leitos, triagem de pacientes e otimização de escalas médicas.

No Brasil, a adoção de tecnologias de análise de dados em saúde ainda é incipiente, especialmente em unidades de médio porte. A maioria dos processos de alocação de pessoal ainda é realizada de forma manual, sem suporte de modelos analíticos (CFM, 2023). Este cenário evidencia a oportunidade e a necessidade de projetos como o desenvolvido neste trabalho.

2.2 Programação Linear Inteira em Problemas de Alocação

A Programação Linear Inteira (PLI) é um ramo da Pesquisa Operacional que trata de problemas de otimização onde as variáveis de decisão são restritas a valores inteiros. A alocação de pessoal em turnos (Staff Scheduling) é um dos problemas clássicos da PLI, amplamente estudado na literatura desde os trabalhos de Dantzig (1954) sobre programação linear.

O modelo de alocação de turnos pode ser formulado como: minimizar o custo total de pessoal sujeito a restrições de cobertura mínima de demanda, limites de contratação e integralidade das variáveis de decisão. Diversas bibliotecas open-source implementam solvers para PLI, sendo o PuLP (com o solver CBC) uma das mais utilizadas no ecossistema Python (Mitchell et al., 2011).

2.3 ETL e Análise de Dados em Python

O processo de ETL (Extract, Transform, Load) é fundamental em projetos de análise de dados. A biblioteca Pandas, criada por McKinney (2010), tornou-se o padrão de facto para manipulação de dados tabulares em Python, oferecendo estruturas de dados eficientes e uma API expressiva para transformações complexas.

A Análise Exploratória de Dados (EDA), conceito introduzido por Tukey (1977), consiste na investigação sistemática de um conjunto de dados através de estatísticas descritivas e visualizações, com o objetivo de identificar padrões, anomalias e hipóteses antes da modelagem formal. Ferramentas como Matplotlib e Seaborn facilitam a geração de visualizações de alta qualidade em Python.

2.4 LGPD e Proteção de Dados em Saúde

A Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018) representa um marco regulatório fundamental para o tratamento de dados pessoais no Brasil, alinhado ao Regulamento Geral de Proteção de Dados (GDPR) da União Europeia. Dados de saúde são classificados como dados pessoais sensíveis pelo Art. 5º, inciso II, e seu tratamento requer base legal específica, conforme o Art. 11.

A anonimização — processo pelo qual um dado perde a possibilidade de associação a um indivíduo — é uma das principais estratégias de conformidade com a LGPD em projetos analíticos. Técnicas como hash criptográfico (SHA-256), generalização e supressão de atributos

identificadores são amplamente recomendadas pela literatura de privacidade de dados (Sweeney, 2002).

3 METODOLOGIA E TECNOLOGIAS UTILIZADAS

3.1 Abordagem Metodológica

O projeto adota uma abordagem aplicada e iterativa, estruturada em cinco fases conforme o cronograma definido no Project Charter: (1) Setup e Organização; (2) Planejamento Base; (3) Execução e Integração; (4) Validação; e (5) Entrega Final. As quatro disciplinas do projeto foram desenvolvidas em paralelo a partir da Fase 2, conforme orientação do professor.

3.2 Dataset Utilizado

O dataset utilizado é o Healthcare Dataset, disponibilizado publicamente na plataforma Kaggle pelo autor Prasad22, sob licença Apache 2.0. O dataset contém 55.500 registros de atendimentos médicos com 15 colunas originais, incluindo dados demográficos, condição médica, datas de internação e alta, tipo de admissão, médico responsável e valor da internação.

Coluna Original	Tipo	Descrição
Name	string	Nome do paciente — anonimizado no ETL via SHA-256
Age	int64	Idade do paciente — generalizada para faixa etária
Gender	string	Gênero (Male/Female)
Blood Type	string	Tipo sanguíneo — dado sensível de saúde (LGPD)
Medical Condition	string	Condição médica — proxy de especialidade no modelo PLI
Date of Admission	string	Data de entrada — convertida para datetime
Doctor	string	Nome do médico responsável
Hospital	string	Nome da unidade de atendimento
Insurance Provider	string	Operadora de saúde
Billing Amount	float64	Valor da internação em R\$
Room Number	int64	Número do quarto
Admission Type	string	Tipo: Emergency / Urgent / Elective
Discharge Date	string	Data de alta — usada para calcular tempo de internação
Medication	string	Medicamento prescrito — dado sensível (LGPD)
Test Results	string	Resultado: Normal / Inconclusive / Abnormal

Fonte: Prasad22 (2023). Healthcare Dataset. Kaggle. Licença Apache 2.0.

3.3 Stack Tecnológico

Tecnologia	Versão	Finalidade
Python	3.14.x	Linguagem principal de todo o desenvolvimento
pandas	3.0.3	ETL, manipulação de DataFrames e agregações
numpy	2.4.5	Operações numéricas e geração de dados sintéticos
matplotlib	3.10.9	Geração dos gráficos do dashboard
seaborn	0.13.2	Visualizações estatísticas (heatmap, boxplot)
PuLP	3.3.1	Modelagem e resolução do modelo PLI
scipy	1.17.1	Análise de sensibilidade
openpyxl	3.1.5	Exportação de resultados para Excel
jupyter	4.x	Ambiente interativo para EDA
Git / GitHub	—	Versionamento do código-fonte
Google Drive	—	Repositório compartilhado com o professor

4 ANÁLISE DE DADOS

4.1 Pipeline ETL (01_etl.py)

O pipeline ETL foi desenvolvido no script 01_etl.py e executado sobre o arquivo healthcare_dataset.csv. O processo é dividido em seis etapas sequenciais:

- **Extração:** Leitura do CSV bruto com `pd.read_csv()`, carregando 55.500 registros e 15 colunas.
- **Limpeza de strings:** Padronização da capitalização de todas as colunas textuais com `str.title()` e `str.strip()`, corrigindo inconsistências como 'Bobby JacksOn' → 'Bobby Jackson'.
- **Conversão de datas:** Conversão das colunas Date of Admission e Discharge Date para o tipo `datetime` com `pd.to_datetime()`.
- **Engenharia de features:** Criação de 10 novas colunas: Shift (turno por hora), Hour of Admission (hora simulada), Wait Time (tempo de espera por tipo de admissão), Length of Stay (dias de internação), Month, Year, Quarter, Weekday, Age Group (faixa etária) e Patient ID (hash anonimizado).
- **Verificação de qualidade:** Checagem de valores nulos (zero encontrados) e duplicatas (1 encontrada, mantida por ser marginal).
- **Exportação:** Geração do arquivo healthcare_clean.csv com 55.500 registros e 24 colunas em data/processed/.

Um aspecto técnico relevante é a anonimização do nome do paciente: o campo Name é substituído por um hash SHA-256 truncado em 8 caracteres (Patient ID) e, em seguida, removido permanentemente do DataFrame antes da exportação, em conformidade com a LGPD.

4.2 Análise Exploratória de Dados — EDA (02_eda.ipynb)

A EDA foi conduzida no Jupyter Notebook 02_eda.ipynb e revelou os seguintes padrões relevantes:

- **Distribuição equilibrada por turno:** Os atendimentos se distribuem uniformemente entre os três turnos — Manhã (33,1%), Tarde (33,8%) e Noite (33,1%) — ao longo do período de 2019 a 2024.
- **Distribuição uniforme por condição médica:** As seis condições médicas (Arthritis, Diabetes, Hypertension, Obesity, Cancer e Asthma) apresentam volumes muito similares, variando entre 9.185 e 9.308 atendimentos totais.
- **Diferenciação por tipo de admissão:** Atendimentos de emergência apresentam menor tempo de espera médio (~15 minutos) em comparação com atendimentos eletivos (~90 minutos), confirmando a lógica de triagem por prioridade clínica.
- **Sazonalidade estável:** Não foram identificados picos pronunciados de demanda por mês ou dia da semana, o que indica uma demanda relativamente estável ao longo do ano — característica comum em datasets sintéticos.
- **Correlações próximas de zero:** As variáveis numéricas (Age, Billing Amount, Length of Stay, Wait Time) apresentam correlações próximas de zero entre si, confirmando a independência das features engineered.

4.3 KPIs e Dashboard (03_kpis_dashboard.py)

Três KPIs principais foram calculados e visualizados no dashboard gerado pelo script 03_kpis_dashboard.py:

KPI	Métrica	Valor Encontrado	Interpretação
KPI 1	Tempo Médio de Espera (TME) geral	58,9 minutos	Acima do benchmark de 30 min para UPAs eficientes
KPI 1	TME por turno (Manhã / Tarde / Noite)	59,1 / 58,9 / 58,7 min	Distribuição uniforme — sem turno crítico isolado
KPI 2	Taxa de Ocupação por Turno	Manhã 33,1% / Tarde 33,8% / Noite 33,1%	Distribuição equilibrada — oportunidade de otimização via PLI
KPI 3	Volume por Condição Médica (top)	Arthritis: 9.308 Asthma: 9.185	Distribuição uniforme entre especialidades

O dashboard compreende seis gráficos exportados em formato PNG: (G1) Boxplot do TME por tipo de admissão; (G2) TME médio por turno em barras; (G3) Taxa de ocupação por turno em pizza; (G4) Volume de atendimentos por condição médica em barras horizontais; (G5) Série histórica de atendimentos por mês em linha; e (G6) Heatmap de atendimentos por hora e dia da semana.

5 PESQUISA OPERACIONAL — MODELO PLI

5.1 Formulação do Problema

O problema de alocação de médicos por turno é formulado como um modelo de Programação Linear Inteira (PLI). O objetivo é determinar o número mínimo de médicos a alocar em cada turno (Manhã, Tarde e Noite) de forma que a demanda diária de atendimentos seja coberta com o menor custo possível de pessoal.

5.2 Definição Formal do Modelo

5.2.1 Conjuntos e Parâmetros

- **Turnos:** $T = \{\text{Manhã, Tarde, Noite}\}$
- **Horas por turno:** $h[t] = 8$ horas para todos os turnos
- **Custo por hora (R\$):** $c[\text{Manhã}] = \text{R\$ } 150,00 \mid c[\text{Tarde}] = \text{R\$ } 150,00 \mid c[\text{Noite}] = \text{R\$ } 180,00$ (adicional noturno CLT)
- **Produtividade:** $p = 4$ atendimentos por médico por hora
- **Demanda média diária:** $d[\text{Manhã}] = 10,0 \mid d[\text{Tarde}] = 10,3 \mid d[\text{Noite}] = 10,1$ atendimentos/dia
- **Mínimo operacional:** $m[\text{Manhã}] = 2 \mid m[\text{Tarde}] = 2 \mid m[\text{Noite}] = 1$ médico(s)
- **Máximo de contratação:** $M = 30$ médicos por turno

5.2.2 Variável de Decisão

$x[t]$ = número de médicos alocados no turno t , onde $x[t]$ é inteiro não-negativo ($x[t] \in \mathbb{Z}^+$).

5.2.3 Função Objetivo

Minimizar: $Z = \sum (t \in T) c[t] \times h[t] \times x[t]$

Ou seja: Minimizar o custo total diário de pessoal somando o produto entre custo horário, horas do turno e número de médicos alocados em cada turno.

5.2.4 Restrições

- **R1 — Cobertura da demanda:** $x[t] \times p \times h[t] \geq d[t]$, para todo $t \in T$
- **R2 — Mínimo operacional:** $x[t] \geq m[t]$, para todo $t \in T$
- **R3 — Limite de contratação:** $x[t] \leq M$, para todo $t \in T$
- **R4 — Integralidade:** $x[t] \in \mathbb{Z}^+$, para todo $t \in T$

5.3 Implementação

O modelo foi implementado no script `modelo_pli.py` utilizando a biblioteca PuLP 3.3.1 com o solver CBC (Coin-or Branch and Cut), incluído gratuitamente no pacote. A demanda diária foi calculada normalizando o total histórico de atendimentos pelo período de 1.826 dias (2019–2024). O pico de demanda foi obtido identificando o dia de maior movimentação em cada turno no histórico real.

5.4 Cenários e Resultados

Cenário	Médicos M/T/N	Status	Custo/dia (R\$)	Observação
C1 — Baseline (manual)	3 / 3 / 2	Manual	R\$ 10.080,00	20% acima do mínimo — ineficiência atual simulada
C2 — Otimizado (PLI)	2 / 2 / 1	Optimal ✓	R\$ 6.240,00	Mínimo custo para a demanda média diária
C3 — Pico (dia crítico)	2 / 2 / 1	Optimal ✓	R\$ 6.240,00	Mesma alocação cobre o dia mais movimentado do histórico

Os resultados revelam que o modelo PLI encontra a solução ótima para os dois cenários com demanda real (C2 e C3), mantendo o mesmo nível de alocação — 2 médicos pela manhã e tarde, 1 à noite — capaz de atender tanto a demanda média quanto o dia de pico. Isso demonstra que a solução é robusta e não requer escalonamento emergencial mesmo nos dias mais movimentados do histórico.

5.5 Análise de Sensibilidade

A análise de sensibilidade avaliou o impacto de variações na demanda (de 70% a 150% da média) sobre o custo total diário. Os resultados demonstram que o custo permanece constante em R\$ 6.240,00 para toda a faixa analisada, pois o fator limitante é o mínimo operacional de segurança ($m[t]$), e não a demanda em si. Esse comportamento é esperado e indica que a alocação mínima já é suficiente para absorver variações substanciais de demanda dentro do nível de produtividade definido.

5.6 Impacto Econômico

Indicador	Valor
Custo diário — Baseline (C1)	R\$ 10.080,00
Custo diário — Otimizado (C2)	R\$ 6.240,00
Economia diária	R\$ 3.840,00 (38,1%)
Economia anual projetada	R\$ 1.401.600,00

6 SEGURANÇA DA INFORMAÇÃO E LGPD

6.1 Mapeamento de Dados Pessoais

O projeto trata dados pessoais de pacientes contidos no dataset público `healthcare_dataset.csv`. O mapeamento completo, conforme documentado em `mapeamento_lgpd.docx`, identificou três categorias de dados:

- **Dados pessoais sensíveis (Art. 5º, II — LGPD):** Medical Condition, Blood Type, Medication e Test Results — tratados exclusivamente de forma agregada, nunca associados ao Patient ID nos outputs.
- **Dados pessoais comuns:** Age Group, Gender, Date of Admission (granularidade reduzida para Month/Year/Quarter), Insurance Provider e Billing Amount.
- **Dados anonimizados:** Patient ID — hash SHA-256 irreversível do nome original, que é removido do dataset após a geração do identificador.

A base legal aplicável é o Art. 7º, inciso IX (legítimo interesse) para dados comuns e o Art. 11, inciso II, alínea f (tutela da saúde) para dados sensíveis. O tratamento é realizado exclusivamente para fins analíticos e acadêmicos, sem coleta de dados reais de pacientes.

6.2 Medidas Técnicas de Proteção

As seguintes medidas técnicas foram implementadas diretamente no pipeline ETL (`01_etl.py`):

- **Anonimização:** `df['Patient ID'] = df['Name'].apply(lambda x: 'PAC-' + hashlib.sha256(x.encode()).hexdigest()[:8].upper())`
- **Remoção do identificador:** `df = df.drop(columns=['Name'])` — executado imediatamente após a geração do hash.
- **Generalização etária:** `pd.cut(df['Age'], bins=[0,18,35,50,65,120], labels=['0-18','19-35','36-50','51-65','65+'])` — substitui a idade exata pela faixa etária.
- **Outputs sempre agregados:** Nenhum gráfico ou tabela de output cruza Patient ID com dados sensíveis de saúde.
- **Acesso restrito ao repositório:** Pasta compartilhada com permissão de leitura apenas para o professor orientador.

6.3 Matriz GUT de Riscos

A Matriz GUT (Gravidade × Urgência × Tendência), documentada em `matriz_gut.xlsx`, identificou 10 riscos de segurança da informação. Os dois riscos de maior prioridade são:

- **R1 — Crítico (GUT = 80):** Exposição de dados sensíveis de saúde por acesso não autorizado ao repositório. Mitigação: permissão de leitura apenas, revogação do link pós-entrega.
- **R2 — Crítico (GUT = 45):** Reidentificação de pacientes por cruzamento de dados. Mitigação: outputs sempre agregados, hash SHA-256 irreversível implementado no ETL.

Dos 10 riscos identificados, 2 foram classificados como Críticos, 3 como Altos, 4 como Médios e 1 como Baixo. Todos os riscos Críticos e Altos possuem plano de mitigação implementado ou documentado.

6.4 Política de Autenticação

A Política de Autenticação e Controle de Acesso, documentada em `politica_autenticacao.docx`, define três perfis de usuário — Administrador (desenvolvedor), Orientador (professor, somente leitura) e Público (sem acesso) — e estabelece requisitos mínimos de autenticação: senha com 12+ caracteres, 2FA ativo na conta do desenvolvedor, token de acesso no Jupyter restrito ao localhost e controle de versão com Git autenticado.

7 GESTÃO DO PROJETO

7.1 Escopo e Estrutura Analítica do Projeto (EAP)

O projeto foi estruturado em seis pacotes de trabalho: (1) Setup e Organização — criação do repositório, README e validação do escopo; (2) Automação de Processos — elaboração do Project Charter, EAP, Gantt e Matriz RACI; (3) Inteligência Artificial / Métodos Numéricos — ETL, EDA, geração do dashboard e modelo PLI; (4) Modelagem e Simulação — formulação e execução dos 3 cenários de otimização; (5) Automação de Processos / Segurança — mapeamento LGPD, Matriz GUT e Política de Autenticação; e (6) Entrega Final — consolidação do PDF ABNT, gravação do vídeo e upload no repositório.

7.2 Cronograma

Fase	Período	Entregáveis
Setup e Organização	13–14/Mai	Repositório, README, Project Charter
ETL + EDA	15–17/Mai	01_etl.py, 02_eda.ipynb, dados processados
KPIs + PLI	17–19/Mai	03_kpis_dashboard.py, modelo_pli.py, gráficos
Segurança / LGPD	19–20/Mai	mapeamento_lgpd.docx, matriz_gut.xlsx, politica_autenticacao.docx
Entrega Final	21–22/Mai	Documento Final PDF, vídeo de 10 minutos

7.3 Matriz RACI

Atividade	Desenvolvedor	Prof. Felipe
Setup do repositório e README	R / A	I
Documentação de Gestão de Projetos	R / A	C / I
ETL e Análise Exploratória de Dados	R / A	I
Desenvolvimento do Modelo PLI	R / A	I
Documentação de Segurança / LGPD	R / A	I
Validação Intermediária (Fase 4)	R	A
Entrega Final (PDF + Vídeo)	R / A	I

Legenda: R = Responsável | A = Aprovador | C = Consultado | I = Informado

8 CONCLUSÃO

O presente trabalho demonstrou a viabilidade e a efetividade da aplicação de técnicas de Inteligência Artificial e Pesquisa Operacional na resolução de um problema real de gestão operacional em saúde. O Sistema Inteligente de Triagem e Alocação de Médicos desenvolvido para a MedFácil Clínicas integrou com sucesso as quatro disciplinas — Inteligência Artificial, Métodos Numéricos Computacionais, Modelagem e Simulação, e Automação de Processos — em uma solução coesa e funcional.

Do ponto de vista técnico, o projeto evidencia que ferramentas open-source do ecossistema Python — Pandas, Matplotlib, Seaborn, PuLP e Jupyter — são suficientes para construir pipelines de análise de dados robustos e modelos de otimização com impacto econômico mensurável. A economia identificada pelo modelo PLI, de 38,1% no custo diário de pessoal e R\$ 1.401.600,00 na projeção anual, demonstra o potencial transformador da abordagem mesmo em contexto simplificado.

A integração da conformidade com a LGPD diretamente no pipeline ETL — através da anonimização por hash SHA-256 e da generalização de atributos identificadores — representa uma boa prática de Privacy by Design que pode ser replicada em projetos reais de saúde digital.

Como trabalhos futuros, sugere-se: (a) a coleta e integração de dados reais de uma UPA, com as devidas autorizações legais; (b) a ampliação do modelo PLI para incluir variáveis de especialidade médica e sazonalidade semanal; (c) o desenvolvimento de uma interface web para visualização em tempo real dos KPIs; e (d) a aplicação de modelos preditivos de demanda (séries temporais, ARIMA, Prophet) para antecipação de picos de atendimento.

REFERÊNCIAS

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, DF, 15 ago. 2018.

CFM — CONSELHO FEDERAL DE MEDICINA. Medicina em números. Brasília: CFM, 2023. Disponível em: <https://www.cfm.org.br>. Acesso em: maio 2026.

DANTZIG, G. B. Linear programming and extensions. Princeton: Princeton University Press, 1963.

MCKINNEY, W. Data structures for statistical computing in Python. In: PROCEEDINGS OF THE 9TH PYTHON IN SCIENCE CONFERENCE, 2010. p. 56-61.

MITCHELL, S.; O'SULLIVAN, M.; DUNNING, I. PuLP: A linear programming toolkit for Python. Auckland: The University of Auckland, 2011. Disponível em: <https://coin-or.github.io/pulp/>. Acesso em: maio 2026.

PRASAD22. Healthcare Dataset. Kaggle, 2023. Disponível em: <https://www.kaggle.com/datasets/prasad22/healthcare-dataset>. Licença Apache 2.0. Acesso em: maio 2026.

SWEENEY, L. k-anonymity: a model for protecting privacy. International Journal on Uncertainty, Fuzziness and Knowledge-based Systems, v. 10, n. 5, p. 557-570, 2002.

TOPOL, E. J. High-performance medicine: the convergence of human and artificial intelligence. Nature Medicine, v. 25, p. 44-56, 2019.

TUKEY, J. W. Exploratory data analysis. Reading: Addison-Wesley, 1977.